Licenciatura en Inteligencia Artificial y Ciencia de Datos — CUGDL

Matemáticas Aplicadas a la Ciencia de Datos

Desarrollo Matemático y Fundamentos Teóricos

K Vecinos más Cercanos (KNN) y **Árboles de Decisión para Clasificación**

En esta sección se hace formalmente el desarrollo matemático y teórico de dos de los algoritmos de aprendizaje supervisado utilizados en el proyecto: el clasificador basado en instancias **K Vecinos más Cercanos (KNN)** y el modelo jerárquico de particionamiento recursivo **Árboles de Decisión para Clasificación** (junto con su extensión por ensamble *Random Forest*). Para cada algoritmo se detallan su formulación matemática, ecuaciones principales, función de costo, algoritmo de optimización, supuestos estructurales e interpretación matemática de hiperparámetros y métricas.

Modelo KNN (Vecinos Cercanos)

1. Formulación Matemática

Sea $\mathcal{D} = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \ldots, (\mathbf{x}_N, y_N)\}$ un conjunto de datos de entrenamiento compuesto por n observaciones, donde cada vector de características se define como $\mathbf{x}_i = (x_{i1}, x_{i2}, \ldots, x_{ip}) \in \mathbb{R}^p$ en un espacio métrico p-dimensional, y $y_i \in \mathcal{C} = \{1, 2, \ldots, K_{\text{clases}}\}$ representa la etiqueta de clase categórica asociada a la i-ésima observación.

El modelo KNN es un método de aprendizaje supervisado basado en instancias (lazy learning o aprendizaje perezoso). A diferencia de los modelos paramétricos que estiman un vector fijo de pesos durante el entrenamiento, KNN proyecta observaciones directamente en el espacio métrico $(\mathbb{R}^p, d)$. Dada una nueva observación de prueba $\mathbf{x} = (x_1, x_2, \ldots, x_p) \in \mathbb{R}^p$, el algoritmo induce un ordenamiento total sobre los elementos de $\mathcal{D}$ en función de su distancia hacia $\mathbf{x}$. A partir de los primeros $K \in \mathbb{Z}$ elementos de dicha permutación ordenada, se define el subconjunto de índices de la **K-vecindad más cercana** a $\mathbf{x}$, denotado como $N_K(\mathbf{x})$:

$$N_K(\mathbf{x}) = \left\{\mathbf{x}_{(1)}, \mathbf{x}_{(2)}, \ldots, \mathbf{x}_{(K)}\right\} \subseteq \mathcal{D} \tag{1}$$

2. Ecuaciones Principales y Métricas de Distancia

- **Distancia de Minkowski (Métrica Generalizada, norma ℓ_q):**

  Es la formulación generalizada de distancia parametrizada por el orden $q \geq 1$:

  $$d_{\text{Minkowski}}(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_q = \left(\sum_{j=1}^{p} |x_j - x_{ij}|^q\right)^{\frac{1}{q}} \tag{2}$$

  Para que $d_{\text{Minkowski}}$ satisfaga los axiomas de un espacio métrico (en particular la desigualdad triangular), se requiere estrictamente que $q \geq 1$.

- **Distancia de Manhattan($q = 1$, norma ℓ_1):**

  Caso particular de la métrica de Minkowski cuando $q = 1$. Cuantifica la suma de las diferencias absolutas a lo largo de cada eje coordenado ortogonal:

  $$d_{\text{Manhattan}}(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_1 = \sum_{j=1}^{p} |x_j - x_{ij}| \tag{3}$$

- **Distancia Euclidiana ($q = 2$, norma ℓ_2):**

  Caso particular de la métrica de Minkowski cuando $q = 2$. Representa la longitud del segmento de recta más corto que une ambos puntos en el espacio euclidiano $\mathbb{R}^p$:

$$d_{\text{Euclidiana}}(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_2 = \sqrt{\sum_{j=1}^{p}(x_j - x_{ij})^2} = \sqrt{(\mathbf{x} - \mathbf{x}_i)^2 + (\mathbf{x} - \mathbf{x}_i)^2} \tag{4}$$

Ecuaciones de Preprocesamiento (Escalamiento de Variables): Dado que cualquier norma ℓ_q depende directamente de la magnitud algebraica de $|x_j - x_{ij}|$, es matemáticamente indispensable aplicar una transformación sobre cada columna $j \in \{1, \ldots, p\}$ antes de calcular distancias:

$$\text{Estandarización (Z-Score):} \quad z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad \text{donde } \mu_j = \frac{1}{N}\sum_{i=1}^{N} x_{ij}, \;\; \sigma_j = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(x_{ij} - \mu_j)^2} \tag{5}$$

$$\text{Normalización Min-Max:} \quad x'_{ij} = \frac{x_{ij} - \min(\mathbf{x}_{\cdot j})}{\max(\mathbf{x}_{\cdot j}) - \min(\mathbf{x}_{\cdot j})} \in [0, 1] \tag{6}$$

3. Función de Costo

El algoritmo KNN carece de una función de costo paramétrica diferenciable durante la fase de ajuste, dado que no optimiza coeficientes internos.

4. Algoritmo de Optimización y Búsqueda

En su implementación directa (fuerza bruta), KNN difiere todo el trabajo computacional a la fase de inferencia mediante un algoritmo de búsqueda exhaustiva de complejidad temporal $\mathcal{O}(N \cdot p)$ por cada muestra evaluada:

1. **Fase de almacenamiento (`fit`):** Se indexa en memoria la matriz estandarizada $\mathbf{X} \in \mathbb{R}^{N \times p}$ y el vector de etiquetas $\mathbf{y} \in \mathcal{C}^N$ con costo computacional $\mathcal{O}(1)$.

2. **Cálculo vectorial de distancias:** Dada una muestra de prueba $\mathbf{x}$, se evalúa el vector de distancias $\mathbf{d} \in \mathbb{R}^N$ donde cada entrada es $d_i = \|\mathbf{x} - \mathbf{x}_i\|_q$ para $i = 1, \ldots, N$.

3. **Selección por ordenamiento parcial:** Se ordena el arreglo de pares (d_i, i) de forma ascendente y se extraen los primeros K índices $\{i_{(1)}, \ldots, i_{(K)}\}$. Esta búsqueda geométrica se acelera mediante particionamiento espacial jerárquico con estructuras de datos como **KD-Trees** o **Ball Trees**, reduciendo la complejidad promedio de consulta a $\mathcal{O}(p \log N)$.

4. **Optimización de hiperparámetros:** La selección del número óptimo de vecinos K^* y la métrica q^* se realiza mediante búsqueda en rejilla con validación cruzada estratificada, minimizando $\mathcal{J}(K, q)$.

5. Supuestos del Modelo

- **Supuesto de suavidad local y continuidad espacial (Hipótesis de Compacidad):** Se asume que puntos cercanos entre sí tienen alta probabilidad de pertenecer a la misma clase; es decir, la función de probabilidad condicional $P(Y = c \mid \mathbf{X} = \mathbf{x})$ es localmente constante dentro de la hiperesfera que encierra a $N_K(\mathbf{x})$.

- **Isotropía e igual relevancia de características:** En las métricas de Minkowski no ponderadas, el modelo asume que todas las dimensiones $j = 1, \ldots, p$ poseen la misma escala y el mismo poder discriminativo. Si existen variables irrelevantes o escalas dispares, la geometría de las distancias se distorsiona severamente.

6. Interpretación Matemática de Parámetros y Métricas

- **Hiperparámetro K (Sesgo-Varianza):** Controla el radio efectivo de la vecindad y el grado de suavidad de la frontera de decisión.
  - Si $K \to 1$, el clasificador tiene **bajo sesgo y alta varianza**: la frontera de decisión es sumamente irregular y se adapta al ruido local, generando **sobreajuste**.
  - Si $K \to N$, el clasificador tiene **alto sesgo y baja varianza**: las regiones locales se promedian en exceso hasta predecir siempre la clase mayoritaria global, provocando **subajuste**.
- **Interpretación Geométrica del Parámetro q:** El conjunto de puntos equidistantes a $\mathbf{x}$ a una distancia r, definido por $B_q(\mathbf{x}, r) = \{\mathbf{z} \in \mathbb{R}^p : \|\mathbf{x} - \mathbf{z}\|_q \leq r\}$, cambia su geometría según q:
  - Para **Manhattan** ($q = 1$) penaliza linealmente las desviaciones y es más robusta frente a valores atípicos extremos en coordenadas individuales.
  - Para **Euclidiana** ($q = 2$), es invariante ante rotaciones ortogonales del espacio de características, pero eleva al cuadrado las diferencias grandes.
  - Para **Minkowski** ($q \to \infty$, **Distancia de Chebyshev**): $\lim_{q\to\infty} \left(\sum_{j=1}^{p} |x_j - x_{ij}|^q\right)^{1/q} = \max_{1\leq j\leq p} |x_j - x_{ij}|$.

Modelo de Árboles de Decisión para Clasificación y Ensamble Random Forest

1. Formulación Matemática

Un Árbol de Decisión para clasificación es un modelo no paramétrico que particiona recursivamente el espacio de características $\mathcal{X} \subseteq \mathbb{R}^p$ en un conjunto de M regiones disjuntas denotadas como $R_1, R_2, \ldots, R_M$. Cada región terminal R_m corresponde a un **nodo hoja** del árbol.

Sea $S_t \subseteq \mathcal{D}$ el subconjunto de muestras de entrenamiento que llegan a un nodo interno o terminal t, con cardinalidad $N_t = |S_t|$. La proporción empírica (probabilidad frecuentista) de observaciones pertenecientes a la clase $k \in \{1, \ldots, K\}$ dentro del nodo t se define como:

$$p_{tk} = \frac{1}{N_t} \sum_{(\mathbf{x}_i, y_i) \in S_t} \mathbb{I}(y_i = k), \qquad \text{cumpliendo que } \sum_{k=1}^{K} p_{tk} = 1 \tag{7}$$

En un nodo hoja m (región R_m), la clase predicha $\hat{c}_m$ se asigna por mayoría simple de las muestras contenidas en dicho nodo:

$$\hat{c}_m = \arg \max_{k \in \{1,\ldots,K\}} p_{mk} \tag{8}$$

De este modo, la función de decisión global del árbol $T(\mathbf{x})$ se expresa formalmente como una combinación de funciones indicadoras sobre las regiones terminales:

$$\hat{y} = T(\mathbf{x}) = \sum_{m=1}^{M} \hat{c}_m \, \mathbb{I}(\mathbf{x} \in R_m) \tag{9}$$

2. Ecuaciones Principales: Medidas de Impureza y Ganancia

Para cuantificar el grado de homogeneidad o desorden de las etiquetas dentro de un nodo t (con distribución de probabilidades), se definen dos funcionales de impureza fundamentales:

- **Entropía de Shannon (utilizada en algoritmos como ID3):** Proveniente de la Teoría de la Información, mide la incertidumbre promedio o el número mínimo de bits necesarios para codificar la clase de una observación seleccionada al azar en el nodo t:

$$H(S_t) = -\sum_{k=1}^{K} p_{tk} \log_2(p_{tk}) \tag{10}$$

  donde por continuidad límite se adopta la convención $0 \log_2(0) = 0$.

- **Índice de Impureza de Gini (utilizado en el algoritmo CART):** Mide la probabilidad esperada de clasificar incorrectamente una observación tomada al azar del nodo t si ésta fuera etiquetada aleatoriamente de acuerdo con la distribución de probabilidades p_{tk} del propio nodo:

$$G(S_t) = \sum_{k=1}^{K} p_{tk}(1 - p_{tk}) = 1 - \sum_{k=1}^{K} p_{tk}^2 \tag{11}$$

Partición de un Nodo y Ganancia de Información:

- **Esquema Multirrama Categórico (ID3):** Si se evalúa un atributo discreto V con categorías posibles $c \in \text{Valores}(V)$, el conjunto S_t se divide en subconjuntos $S_{t,V=c} = \{(\mathbf{x}_i, y_i) \in S_t : x_{iV} = c\}$. La **Ganancia de Información** $\Delta H(S_t, V)$ es la reducción esperada en la entropía:

$$\Delta H(S_t, V) = H(S_t) - \sum_{c \in V} \frac{|S_{t,V=c}|}{|S_t|} H(S_{t,V=c}) \tag{12}$$

- **Esquema Binario para Variables Continuas (CART):** Para una variable predictora $j \in \{1, \ldots, p\}$ y un umbral de corte $\tau \in \mathbb{R}$, el nodo S_t se divide en dos nodos hijos: izquierdo $S_L(j, \tau) = \{(\mathbf{x}_i, y_i) \in S_t : x_{ij} \leq \tau\}$ y derecho $S_R(j, \tau) = \{(\mathbf{x}_i, y_i) \in S_t : x_{ij} > \tau\}$. Sea $I(\cdot) \in \{G(\cdot), H(\cdot)\}$ la medida de impureza elegida; la **reducción de impureza** $\Delta I(S_t, j, \tau)$ es:

$$\Delta I(S_t, j, \tau) = I(S_t) - \left(\frac{N_L}{N_t} I(S_L(j, \tau)) + \frac{N_R}{N_t} I(S_R(j, \tau)) \right) \tag{13}$$

  donde $N_L = |S_L(j, \tau)|$ y $N_R = |S_R(j, \tau)|$, cumpliendo $N_L + N_R = N_t$.

3. Función de Costo

En la construcción del árbol, la optimización se formula a nivel local en cada nodo interno y a nivel global para la regularización (poda):

- **Función de Costo Local de Partición (Criterio de Corte CART):** En cada nodo t, encontrar el par óptimo (j^*, τ^*) que maximiza la ganancia de información $\Delta I(S_t, j, \tau)$ es matemáticamente equivalente a **minimizar la impureza ponderada de los nodos hijos**, dado que $I(S_t)$ es constante respecto a (j, τ):

$$\mathcal{J}_{\text{split}}(j, \tau) = \frac{N_L}{N_t} I(S_L(j, \tau)) + \frac{N_R}{N_t} I(S_R(j, \tau)) \tag{14}$$

$$(j^*, \tau^*) = \arg \min_{j \in \mathcal{F}_t,\, \tau \in \mathcal{T}_j} \mathcal{J}_{\text{split}}(j, \tau) \tag{15}$$

- **Función de Costo Global con Penalización por Complejidad (Poda Costo-Complejidad):** Para evitar que el árbol T crezca indefinidamente memorizando el conjunto de entrenamiento, la función de costo global combina la impureza acumulada en sus $|T|$ hojas terminales con un término de regularización proporcional al número de hojas:

$$R_\alpha(T) = \sum_{m=1}^{|T|} \frac{N_m}{N} I(R_m) + \alpha |T| \tag{16}$$

donde $\alpha \geq 0$ penaliza la complejidad estructural del árbol.

4. Algoritmo de Optimización: Inducción Voraz

Determinar el árbol binario globalmente óptimo es un problema computacionalmente intratable (**NP-Completo**). Por ello, los algoritmos ID3 y CART emplean una heurística de optimización **voraz (*greedy*) de arriba hacia abajo (*top-down*)** mediante particionamiento recursivo:

1. **Inicialización en la Raíz:** Se inicia en el nivel de profundidad $d = 0$ con la totalidad del conjunto de datos $S_0 = \mathcal{D}$ y se calcula la impureza basal $I(S_0)$.

2. **Búsqueda Exhaustiva Local:** En el nodo actual t, se selecciona el subconjunto de características candidatas $\mathcal{F}_t \subseteq \{1, \ldots, p\}$ (todas las columnas en un árbol estándar, o un subconjunto aleatorio de tamaño $m_{\text{try}} = \lfloor \sqrt{p} \rfloor$ en cada nodo de un *Random Forest*). Para cada característica $j \in \mathcal{F}_t$, se evalúan todos los umbrales candidatos τ y se selecciona el par (j^*, τ^*) que minimiza $\mathcal{J}_{\text{split}}(j, \tau)$.

3. **Ramificación Recursiva:** Se divide S_t en $S_L(j^*, \tau^*)$ y $S_R(j^*, \tau^*)$ y se invoca recursivamente el procedimiento en ambos subnodos incrementando la profundidad a $d + 1$.

4. **Criterios de Parada (Poda Previa):** La recursión se detiene y el nodo t se declara nodo hoja si se cumple cualquiera de las siguientes condiciones:

   - Pureza absoluta: $I(S_t) = 0$ (todas las muestras pertenecen a una única clase).
   - Límite de profundidad máxima alcanzado: $d \geq$ max_depth.
   - Tamaño muestral insuficiente para dividir: $N_t <$ min_samples_split.
   - Ninguna partición produce una reducción estricta de impureza ($\Delta I \leq 0$).

5. Supuestos del Modelo

- **Fronteras de decisión ortogonales a los ejes:** Al evaluar condiciones de la forma $x_{ij} \leq \tau$ sobre una variable a la vez, el árbol asume que las clases pueden separarse mediante hiperplanos perpendiculares a los ejes coordenados.

- **Ausencia de supuestos distributivos e invarianza ante transformaciones monótonas:** No asume normalidad, linealidad ni homocedasticidad. Además, dado que los cortes dependen únicamente del orden relativo de los valores x_{ij}, el árbol es completamente invariante al escalamiento, estandarización o cualquier transformación estrictamente creciente de las variables predictoras.

- **Optimalidad local como aproximación de optimalidad global:** Se asume que maximizar la ganancia de información paso a paso en cada nodo conduce a una estructura global discriminativa satisfactoria.

6. Interpretación Matemática de Parámetros y Métricas

- **Cotas de Impureza (Gini vs. Entropía):**

  - **Nodo Puro (Mínimo):** Si existe una clase k^* tal que $p_{tk^*} = 1$ y $p_{tk} = 0$ para todo $k \neq k^*$, entonces $G(S_t) = 1 - 1^2 = 0$ y $H(S_t) = -1\log_2(1) = 0$.
  - **Máxima Incertidumbre (Distribución Uniforme):** Si las K clases son equiprobables dentro del nodo ($p_{tk} = \frac{1}{K}$ para todo k), ambas funciones alcanzan su máximo global:

$$G_{\max} = 1 - \sum_{k=1}^{K} \left(\frac{1}{K}\right)^2 = 1 - \frac{1}{K} \tag{17}$$

$$H_{\max} = -\sum_{k=1}^{K} \frac{1}{K} \log_2\left(\frac{1}{K}\right) = \log_2(K) \tag{18}$$

- **Importancia de Características (*Mean Decrease in Impurity*, MDI):** La relevancia matemática de cada variable predictora $j \in \{1, \ldots, p\}$ (atributo `feature_importances_`) mide la reducción total de impureza ponderada que aportó dicha variable en todos los nodos internos $t \in \mathcal{I}_j$ donde fue utilizada para dividir, normalizada para sumar 1:

$$\text{Importancia}(j) = \frac{\sum_{t \in \mathcal{I}_j} \frac{N_t}{N} \Delta I(S_t, j, \tau_t)}{\sum_{l=1}^{p} \sum_{t \in \mathcal{I}_l} \frac{N_t}{N} \Delta I(S_t, l, \tau_t)} \in [0, 1] \tag{19}$$

- **Estimador *Out-of-Bag* (OOB) en Random Forest:** En un muestreo con reemplazo de tamaño N, la probabilidad de que una observación específica $(\mathbf{x}_i, y_i)$ no sea seleccionada en la muestra bootstrap de un árbol es $\left(1 - \frac{1}{N}\right)^N \xrightarrow{N\to\infty} e^{-1} \approx 0.3679$ (36.8%). Sea $\mathcal{B}^{(-i)} \subset \{1, \ldots, B\}$ el subconjunto de árboles para los cuales la muestra i quedó fuera de la bolsa (OOB). El **OOB Score** evalúa la exactitud de generalización sin requerir un conjunto de validación externo:

$$\text{OOB Score} = \frac{1}{N} \sum_{i=1}^{N} \mathbb{I}\left(y_i = \text{mode}_{b \in \mathcal{B}^{(-i)}} \left\{T_b(\mathbf{x}_i)\right\}\right) \tag{20}$$

- **Hiperparámetros de Poda (`max_depth`, `min_samples_split`, `min_samples_leaf`):** Un árbol con profundidad d puede generar hasta 2^d hojas terminales. Disminuir `max_depth` o incrementar `min_samples_split` restringe el número máximo de regiones M, reduciendo la varianza del modelo y previniendo el sobreajuste.